



UNIVERSIDAD DON BOSCO



MAESTRÍA EN CIENCIA DE DATOS E INTELIGENCIA DE NEGOCIOS

DOCENTE:

Mg. Joel Orellana

INTEGRANTES


GZ130034 Galicia Zavaleta Eduardo Andrés

HR150875 Hernández Rodríguez Fernando José

HV252954 Huevo Vasquez William Alexander

PB252919 Portillo Bellos Daniel Roberto

ZM252743 Zuñiga Martinez Francisco Ramon



INTRODUCCIÓN

Como grupo, hemos seleccionado este conjunto de datos eléctricos porque nuestro objetivo principal es entender en profundidad el comportamiento de consumo de un cliente industrial. Este dataset, generado por una empresa de distribución eléctrica, registra las variables de telemetría de un cliente industrial durante un periodo de un mes. Es importante notar que, por ser un dataset con información sensible, se procedió a omitir cualquier dato que pudiera identificar al cliente.

La selección se justifica porque, para una gestión energética moderna, no es suficiente saber cuánta electricidad se gasta en total (el KWH), sino que es crucial entender cómo, cuándo y con qué eficiencia se está utilizando esa energía. Por lo tanto, este dataset es ideal, ya que contiene las variables eléctricas de medición necesarias para realizar análisis que pueden ayudar a otras áreas más operativas a identificar ineficiencias y posibles problemas.

OBJETIVOS DEL PROYECTO

Objetivo General

Aplicar técnicas de aprendizaje no supervisado para identificar perfiles operativos y anomalías en datos de consumo eléctrico industrial.

Objetivos Específicos:


1. Explorar y preprocesar datos de medición eléctrica trifásica
2. Aplicar y comparar técnicas de reducción dimensional (PCA y UMAP)
3. Implementar algoritmos de clustering (K-means y DBSCAN)
4. Caracterizar perfiles operativos identificados
5. Generar recomendaciones accionables

Alcance

- **Temporal:** Datos de octubre 2025 (un mes completo)
- **Espacial:** Un cliente industrial único
- **Técnico:** Análisis descriptivo y clustering, sin predicción
- **Limitaciones:** Resultados no generalizables a otros clientes sin validación

JUSTIFICACIÓN

Como grupo, hemos seleccionado este conjunto de datos eléctricos porque nuestro objetivo principal es entender en profundidad el comportamiento de consumo de un cliente industrial. Para



una gestión energética moderna, no es suficiente saber cuánta electricidad se gasta en total (el KWH), sino que es crucial entender cómo, cuándo y con qué eficiencia se está utilizando esa energía.

Características:

- 2.881 observaciones (intervalos de 15 minutos)
- 47 variables originales de medición eléctrica trifásica
- Periodo: 1-31 de octubre de 2025
- Sin valores faltantes (0% valores faltantes)

Variables Principales:

Categoría	Variables	Descripción
Consumo	KWHD, KVAHD, KWD, KVAD	Energía activa y reactiva
Voltaje	VA, VB, VC, VX_DESV	Voltajes por fase y desviaciones
Corriente	IA, IB, IC, IX_DESV	Corrientes por fase y desviaciones
Calidad	THD_CORRIENTE_FASE_X, THD_VOLT_FASE_X	Distorsión armónica total
Temporal	FECHA, HORA, INTERVALO	Contexto temporal

METODOLOGÍA EMPLEADA

ANÁLISIS EXPLORATORIO DE DATOS


El análisis exploratorio de datos constituye la primera etapa del procesamiento y comprensión de los registros provenientes del sistema de medición energética. Su objetivo es identificar patrones de comportamiento, distribuciones, valores atípicos y relaciones preliminares entre las variables más relevantes del conjunto de datos. Para este estudio se analizan cuatro variables energéticas fundamentales: energía activa (KWHD), energía aparente (KVAHD), demanda de potencia activa (KWD) y demanda de potencia aparente (KVAD).

DISTRIBUCIÓN DE VARIABLES DE CONSUMO ENERGÉTICO

Distribución de Energía Activa (KWHD)

La energía activa corresponde a la energía efectivamente utilizada por la instalación. Su distribución muestra una asimetría positiva clara, con la mayoría de los valores concentrados





entre 5 y 10 kWh y una cola extendida hacia consumos mayores. La media observada (≈ 14.32 kWh), indicada por la línea vertical roja se ubica por encima del grupo con mayor frecuencia, lo que confirma el sesgo hacia la derecha. Este patrón sugiere que, aunque en general el consumo se mantiene en niveles bajos o moderados, existen periodos en los que aumenta debido a mayores demandas operativas o al uso simultáneo de equipos con alto requerimiento energético.

Distribución de Energía Aparente (KVAHD)

La energía aparente presenta un comportamiento similar al de la energía activa. La mayoría de los valores se concentran en el rango de 5 a 10 kVAh, con una distribución que se extiende hacia valores mayores. La media registrada (≈ 14.53 kVAh) es cercana a la observada en la variable de energía activa, lo que indica una relación estable entre ambas magnitudes. No obstante, la existencia de valores más altos sugiere periodos en los que la carga reactiva aumenta, posiblemente asociados al funcionamiento de equipos con componentes inductivos.


Distribución de la Demanda de Potencia Activa (KWD)


La demanda de potencia activa presenta una variabilidad amplia, con varios incrementos distribuidos a lo largo del rango observado. La mayor concentración de valores se encuentra entre 20 y 30 kW, aunque existe una cola extendida que supera los 140 kW. La media (≈ 57.28 kW) se ubica claramente por encima del grupo con mayor frecuencia, lo que refleja la presencia de momentos con requerimientos elevados de potencia. Estos incrementos pueden corresponder a periodos de mayor actividad operativa o al uso de equipos que demandan cargas superiores.

Distribución de la Demanda de Potencia Aparente (KVAD)

La demanda de potencia aparente muestra un comportamiento similar al de la demanda de potencia activa, con valores ligeramente mayores debido al componente reactivo. La media (≈ 58.10 kVA) es consistente con la tendencia observada en la variable de potencia activa, lo que sugiere un factor de potencia relativamente estable en el conjunto de datos. Sin embargo, los valores altos en el extremo derecho indican periodos en los que la instalación opera con niveles de carga elevados, lo que podría influir en el desempeño general del sistema eléctrico.

	KWHD	KVAHD	KWD	KVAD
count	2881	2881	2881	2881
mean	14.32	14.53	57.28	58.10
std	7.89	8.09	31.56	32.37
min	0.48	2.10	1.92	8.40
25%	6.24	6.24	24.96	24.96
50%	14.34	14.34	57.36	57.36
75%	20.76	21.00	83.04	84.00
max	36.66	37.92	146.64	151.68





Los gráficos presentan una asimetría positiva muy marcada, la mayoría de las mediciones se concentran en consumos bajos o moderados (moda entre 5 y 30 unidades). Sin embargo, la media es notablemente superior a la moda debido a la existencia de picos de consumo y demanda muy elevados que se extienden hasta 140 kVA/kW. Esto concluye que el sistema opera principalmente con bajo consumo base, pero está sujeto a picos de demanda extremos y significativos.

DISTRIBUCIÓN DE VOLTAJES POR FASE

Distribución de la Variable VA

La variable VA presenta una distribución muy cercana a la simetría. La mayoría de los valores se concentran alrededor de la media (13309.50), con una muy baja variabilidad indicada por su desviación estándar (84.25). La media y la mediana (13308.10) son prácticamente idénticas, lo que confirma la ausencia de un sesgo fuerte. Este patrón sugiere que las mediciones se mantienen estables y concentradas en un nivel constante, con desviaciones mínimas hacia valores extremos.

Distribución de la Variable VB


La variable VB presenta una distribución con ligera asimetría negativa. La mayoría de los valores se concentran en el rango superior del conjunto de datos, con una mediana (13368.10) superior a la media (13309.50). La desviación estándar es de 86.19. No obstante, la variabilidad es baja

y similar a la de las otras variables, lo que indica un comportamiento estable. La asimetría negativa sugiere que la ocurrencia de mediciones notablemente bajas es menos frecuente que las altas, creando una cola extendida hacia los valores menores.

Distribución de la Variable VC

La variable VC presenta un nivel promedio más alto que las otras dos, con una media de 13441.79 y una mediana de 13440.10. La distribución es esencialmente simétrica, al igual que VA. Su desviación estándar (83.32) es la más baja de las tres. Este patrón indica que, aunque el nivel de operación es superior al de VA y VB, la estabilidad de sus mediciones es máxima, con una concentración muy estrecha alrededor de su promedio. El nivel superior podría reflejar diferencias en el punto de medición o la carga específica de esta fase.

	VA	VB	VC
count	2881.00	2881.00	2881.00
mean	13309.50	13309.50	13441.79
std	84.25	86.19	83.32
min	13080.10	13128.10	13224.10
25%	13248.10	13308.10	13380.10
50%	13308.10	13368.10	13440.10
75%	13368.10	13428.10	13500.10
max	13572.10	13632.10	13692.10



Los tres gráficos de Voltaje (VA, VB, VC) presentan una distribución altamente simétrica con una forma acampanada, lo cual contrasta fuertemente con la asimetría observada en la Demanda. La moda y la media se ubican en el centro del histograma, confirmando la alta estabilidad y baja dispersión de las mediciones de voltaje. Esto concluye que el sistema opera con una excelente calidad de energía en el componente de voltaje, aunque se registra un ligero desbalance en los niveles promedio (VA 13309.50 V < VC 13441.79V).

DISTRIBUCIÓN DE CORRIENTES POR FASE

Distribución de la Variable IA

La variable IA presenta una distribución con una asimetría positiva muy marcada. La mayoría de los valores se concentran en el rango bajo, pues el mínimo (0.00) es igual al percentil 25 (0.00), lo que indica que al menos el 25 por ciento de las mediciones son nulas. La mediana (1.00) se ubica notablemente por encima de la media (0.63). Este patrón sugiere que, aunque la corriente se mantiene generalmente en niveles muy bajos o nulos, la distribución se extiende hacia valores mayores (máximo de 3.00), lo que "jala" la media hacia la derecha. La desviación estándar (0.69) es alta en relación a la media, confirmando la gran dispersión.


Distribución de la Variable IB

La variable IB también muestra una distribución con asimetría positiva. Al igual que IA, la mayoría de los valores se concentran en el rango bajo, con el mínimo (0.00) y el percentil 25 (0.00) en cero. La media (0.85) es inferior a la mediana (1.00). Sin embargo, el percentil 75 (2.00) es más alto que el de IA, lo que sugiere que IB registra valores de corriente ligeramente superiores en sus cuartiles superiores. La diferencia entre la media y la mediana es menor que en IA, indicando un sesgo menos extremo. La desviación estándar (0.83) es la mayor de las tres, lo que confirma su alta dispersión.

Distribución de la Variable IC

La distribución de la variable IC presenta un comportamiento y estadísticas descriptivas casi idénticas a las de IB. La asimetría positiva está presente, con una media (0.85) inferior a la mediana (1.00). El mínimo, el percentil 25 (0.00) y la mediana (1.00) son los mismos que en IB. Esta similitud en los percentiles clave (incluyendo el percentil 75 en 2.00) sugiere que las fases IB e IC comparten patrones de concentración de corriente muy parecidos. La desviación estándar (0.89) es la más alta entre las tres, lo que es impulsado por los valores extremos, y se compara con un máximo de 3.00.

	IA	IB	IC
count	2881.00	2881.00	2881.00
mean	0.63	0.85	0.85
std	0.69	0.83	0.89
min	0.00	0.00	0.00
25%	0.00	0.00	0.00
50%	1.00	1.00	1.00
75%	1.00	2.00	2.00
max	3.00	3.00	3.00



DISTRIBUCIÓN DE THD (TOTAL HARMONIC DISTORTION)

El Total Harmonic Distortion (THD) puede entenderse, de manera simplificada para fines de este reporte, como una medida que cuantifica qué tanta distorsión presenta una señal eléctrica respecto a la forma que debería tener idealmente. En términos prácticos, representa la “suciedad” presente en la señal de voltaje o corriente en un punto de medición: mientras más alto es el THD, mayor es el nivel de alteraciones o irregularidades superpuestas a la onda fundamental. A continuación, lo encontrado para cada una de las fases en voltajes y corrientes.

Distribución de THD CORRIENTE FASE A

La distribución de la Distorsión Armónica Total de Corriente para la Fase A presenta un comportamiento prácticamente simétrico. La mayoría de los valores se concentran alrededor de la media (0.27), siendo esta idéntica a la mediana (0.27). Esto sugiere una distribución equilibrada de las mediciones. La desviación estándar (0.12) es relativamente baja, lo que indica que las mediciones de THD se mantienen estables y concentradas. El rango de valores se extiende desde un mínimo de 0.08 hasta un máximo de 1.00, con el 50 por ciento central entre 0.17 y 0.36.

Distribución de THD CORRIENTE FASE B


La distribución de THD para la Fase B presenta una ligera asimetría positiva (sesgo a la derecha). La media (0.20) es superior a la mediana (0.19). Esto indica que la mayoría de los valores de THD se concentran en el rango inferior. Esta fase registra el nivel promedio de THD más bajo (0.20) entre las tres. Su desviación estándar (0.08) es la más baja, lo que la convierte en la fase con la mayor estabilidad y menor variabilidad en sus niveles de distorsión armónica. El rango Inter cuartil (de 0.15 a 0.24) es el más estrecho, mostrando una alta concentración.

Distribución de THD CORRIENTE FASE C

La distribución de THD para la Fase C presenta también una asimetría positiva. La media (0.29) es superior a la mediana (0.25). Esta fase registra el nivel promedio de THD más alto (0.29). Su desviación estándar (0.16) es la más alta entre las tres fases, lo que indica la mayor variabilidad y dispersión en sus mediciones de distorsión. Aunque su mediana es baja, el rango Inter cuartil (de

0.15 a 0.43) es el más amplio, y los valores se extienden hasta un máximo de 1.00, lo que sugiere la ocurrencia de picos de distorsión más altos y dispersos que en las otras fases.

	THD_CORRIENTE_FAS E_A	THD_CORRIENTE_FAS E_B	THD_CORRIENTE_FA SE_C
count	2881.00	2881.00	2881.00
mean	0.27	0.20	0.29
std	0.12	0.08	0.16
min	0.08	0.05	0.06
25%	0.17	0.15	0.15
50%	0.27	0.19	0.25
75%	0.36	0.24	0.43
max	1.00	1.00	1.00



Como se observa en los histogramas la THD de Corriente presenta niveles promedio altos y una alta variabilidad (entre 0.20 y 0.29), con distribuciones sesgadas positivamente debido a la existencia de picos de distorsión. Esto indica una calidad de energía deficiente en el componente de corriente, siendo la Fase C la más afectada (mayor promedio y dispersión), mientras que la Fase B es la más estable y "limpia" (menor promedio).

Distribución de THD VOLT FASE A

La distribución de la Distorsión Armónica Total de Voltaje para la Fase A presenta un comportamiento prácticamente simétrico y de extrema estabilidad. La mayoría de los valores se concentran alrededor de la media (0.02), siendo esta idéntica a la mediana (0.02), lo que confirma la ausencia de un sesgo en la distribución central. La desviación estándar es de 0.02. Esto indica que el nivel de distorsión se mantiene estable y concentrado en un nivel muy bajo. El rango de valores es notable por su máximo de 0.96. Dado que el 75 por ciento de los valores es 0.02, este máximo es un valor atípico extremo que no afecta la alta calidad de la onda de voltaje.


Distribución de THD VOLT FASE B

La distribución de THD de Voltaje para la Fase B es altamente estable, la media (0.02) es idéntica a la mediana (.02) y a los cuartiles, lo que sugiere una distribución esencialmente nula y simétrica. La desviación estándar es de 0.01, la más baja de las tres fases, lo que indica la estabilidad máxima en sus mediciones. Este patrón confirma que el nivel de distorsión armónica es insignificante, y la concentración de valores es perfecta. El valor máximo de 0.14 no afecta esta conclusión de estabilidad excelente.

Distribución de THD VOLT FASE C


La distribución de THD de Voltaje para la Fase C también muestra una estabilidad máxima. La media (0.02) es idéntica a la mediana (0.02) y el mínimo es 0.02. La desviación estándar es de 0.01, lo cual es extremadamente bajo. Este patrón indica que la calidad del voltaje suministrado es altísima. Aunque el máximo es 0.15, la distribución esencialmente nula (concentración del 75 por ciento en 0.02) garantiza que la distorsión armónica en esta fase se mantiene constante y muy por debajo de los límites de preocupación.

	THD_VOLT_FASE_A	THD_VOLT_FASE_B	THD_VOLT_FASE_C
count	2881.00	2881.00	2881.00
mean	0.02	0.02	0.02
std	0.02	0.01	0.01
min	0.02	0.01	0.02
25%	0.02	0.02	0.02
50%	0.02	0.02	0.02
75%	0.02	0.03	0.02
max	0.96	0.14	0.15




Los histogramas muestran que la Distorsión Armónica Total de Voltaje es excelente y extremadamente estable en las tres fases, con promedios que oscilan alrededor de 0.022 a 0.023. La distribución visual es hiper-concentrada en un único punto, lo que confirma una calidad de onda de voltaje óptima y mínima fluctuación de armónicos.

ANÁLISIS EXPLORATORIO BIVARIADO



La matriz de correlación evidencia una estructura trifásica coherente y altamente correlacionada, con un comportamiento energético dominado por el consumo y patrones estables de corriente y tensión. Sin embargo, la distorsión armónica introduce no linealidades importantes, especialmente bajo condiciones de baja carga, lo que justifica completamente el uso de técnicas no supervisadas como PCA, UMAP y DBSCAN para descubrir modos de operación, picos y anomalías. El análisis bivariado confirma la presencia de relaciones físicas fundamentales y revela oportunidades para interpretación avanzada en las fases posteriores del proyecto.

ANÁLISIS TEMPORAL



El análisis de los gráficos de consumo promedio por hora revela un patrón bimodal de alta variabilidad, típico de operaciones con horarios fijos.

Los tres gráficos (Energía Activa KWH, Energía Aparente KVAH y Demanda de Potencia Activa KWD) presentan un patrón bimodal de consumo y demanda diaria, el consumo es mínimo durante la madrugada (aproximadamente de 0:00 a 6:00); se observa un primer pico en la mañana (alrededor de 8:00, alcanzando su máximo absoluto a las 11:00 horas), y un segundo pico significativo en la tarde/noche (aproximadamente de 18:00 a 20:00), antes de caer nuevamente a niveles mínimos.

La desviación estándar indica que la variabilidad es extremadamente baja durante la noche (0:00 a 6:00), lo cual sugiere un consumo de base muy estable (consumo fijo de equipos auxiliares), por el contrario, la variabilidad es máxima durante las horas pico operacionales (8:00 a 20:00), lo que implica que la intensidad de la producción y la demanda industrial fluctúan considerablemente de un día a otro. Interpretación: El sistema muestra un comportamiento de carga predecible con una clara división entre periodos de actividad y periodos de inactividad. El pico de la tarde (18:00 a 20:00) en la demanda de potencia (KWD) sugiere un alto requerimiento energético al cierre de la jornada, posiblemente asociado al funcionamiento de procesos críticos o al uso simultáneo de equipos de alta potencia.

FEATURE ENGINEERING

Distribución del Factor de Potencia

El Factor de Potencia presenta una distribución con fuerte asimetría negativa. La mayoría de los valores se concentran en el límite superior del conjunto de datos, con una mediana (1.00) ligeramente superior a la media (0.99). La desviación estándar es de 0.05. No obstante, la variabilidad es baja, lo que confirma que el sistema es altamente eficiente y estable la mayor parte del tiempo. La asimetría negativa sugiere que la ocurrencia de valores muy bajos (mínimo de 0.20) es esporádica, creando una cola extendida hacia la ineficiencia y afectando el promedio general.

Distribución del Desbalance de Corriente

El Desbalance de Corriente presenta una distribución con extrema asimetría positiva. La mayoría de los valores se concentran en el rango mínimo, con la mediana (0.00) siendo drásticamente inferior a la media (0.17). La desviación estándar de 0.39 es muy alta en comparación con la media. Este patrón sugiere que, si bien el sistema está bien balanceado la mayoría del tiempo, existe una ocurrencia significativa de picos de desbalance, los cuales alcanzan un máximo de 1.73, lo que eleva el promedio general y refleja una inestabilidad ocasional de la carga en las fases.

Distribución del Desbalance de Voltaje

El Desbalance de Voltaje presenta una distribución esencialmente simétrica y nula. La mayoría de los valores se concentran alrededor de la media (0.01), con una desviación estándar de 0.00. La media y la mediana (0.00) son prácticamente idénticas y extremadamente cercanas a cero. Este patrón indica que, el nivel de desbalance es el más bajo registrado, la estabilidad de sus mediciones es máxima, y la concentración es nula. El valor máximo de 0.01 certifica la altísima calidad y balance del voltaje suministrado.

	FACTOR_POTENCIA	DESBALANCE_CORRIENTE	DESBALANCE_VOLTAJE
count	2881.00	2881.00	2881.00
mean	0.99	0.17	0.01
std	0.05	0.39	0.00
min	0.20	0.00	0.00
25%	0.98	0.00	0.00
50%	1.00	0.00	0.00
75%	1.00	0.25	0.01
max	1.01	1.73	0.01

Distribución del THD Corriente Promedio

La Distorsión Armónica Total de Corriente Promedio presenta una distribución muy cercana a la simetría, la mayoría de los valores se concentran alrededor de la media (0.25), siendo esta casi idéntica a la mediana (0.24). La desviación estándar es de 0.12. No obstante, la variabilidad es baja, lo que confirma que el nivel de distorsión se mantiene estable la mayor parte del tiempo. La presencia del valor máximo (1.00) sugiere que existen picos de distorsión muy altos que, aunque esporádicos, influyen en la dispersión general del sistema.


Distribución del THD Voltaje Promedio

La Distorsión Armónica Total de Voltaje Promedio presenta una distribución esencialmente simétrica y nula. La mayoría de los valores se concentran alrededor de la media (0.02), siendo esta idéntica a la mediana (0.02). La desviación estándar es de 0.01. Este patrón indica que, el nivel de distorsión armónica es extremadamente bajo, la estabilidad de sus mediciones es máxima, y la concentración es nula. Aunque el valor máximo alcanza 0.42, el conjunto de datos certifica la altísima calidad y limpieza de la onda de voltaje.

Distribución del KVAR Aparente

El KVAR Aparente presenta una distribución con extrema asimetría positiva. La mayoría de los valores se concentran en el rango mínimo, con la mediana (0.00) siendo drásticamente inferior a la media (1.75). La desviación estándar de 2.49 es muy alta en comparación con la media. Este patrón sugiere que, la potencia reactiva es nula o muy baja la mayor parte del tiempo, lo cual se ve en el 75 por ciento de las mediciones que son 3.12 o menos. La asimetría positiva se debe a la ocurrencia de picos muy altos, que alcanzan un máximo de 11.36, lo que eleva el promedio general y refleja periodos de alta demanda de potencia reactiva


	THD_CORRIENTE_PROMEDIO	THD_VOLTAJE_PROMEDIO	KVAR_APARENTE
count	2881.00	2881.00	2881.00
mean	0.25	0.02	1.75
std	0.12	0.01	2.49
min	0.07	0.02	0.00
25%	0.16	0.02	0.00
50%	0.24	0.02	0.00
75%	0.34	0.02	3.12
max	1.00	0.42	11.36



DETECCIÓN DE OUTLIERS

Boxplots revela que los picos de consumo y demanda (KWH, KWD) son parte de la variación operativa normal (cero outliers detectados por IQR). Sin embargo, la calidad de la carga presenta inestabilidad.

El Factor de Potencia, aunque excelente en la mediana (1.00), sufre un 8.3 por ciento de outliers que bajan la eficiencia, y el Desbalance de Corriente registra un 7.0 por ciento de eventos atípicos significativos, estos problemas de la carga contrastan con el Desbalance de Voltaje, que es excepcionalmente estable (0.3 por ciento de outliers), confirmando la alta calidad del suministro.



RESULTADOS DE LA REDUCCIÓN DE DIMENSIONALIDAD


Análisis de Componentes Principales (PCA)

Visualizar Scree Plot y varianza acumulada


El Scree Plot muestra que la mayor parte de la variabilidad del sistema se concentra en los primeros componentes principales. El CP1 y el CP2 explican aproximadamente el 38% y 21% de la varianza, respectivamente, lo que evidencia que las magnitudes asociadas a carga eléctrica —como energía activa, potencia demandada y corrientes por fase— son las que definen el comportamiento general del sistema. A partir del CP3, cuya contribución ronda el 10%, la variabilidad capturada corresponde a efectos secundarios relacionados con fluctuaciones entre fases y otros fenómenos no dominantes. La disminución rápida de la varianza explicada confirma una fuerte correlación entre variables, característica de sistemas donde energía, potencia y corrientes evolucionan de manera conjunta.

Los componentes posteriores muestran una contribución marginal y representan principalmente variabilidad residual asociada a desbalances menores, picos aislados o ruido. Esto coincide con la ausencia de patrones anómalos persistentes en los análisis previos. La varianza acumulada indica que es posible conservar entre el 90% y 95% de la información utilizando entre 7 y 11

componentes, lo que confirma la eficiencia del PCA para reducir dimensionalidad sin perder la estructura fundamental del sistema eléctrico. En conjunto, el análisis refleja un sistema estable, donde los fenómenos más relevantes pueden describirse adecuadamente con un número reducido de componentes.




Visualización PCA 2D coloreado por hora del día



El análisis PCA 2D revela que el sistema eléctrico presenta modos operativos bien diferenciados, organizados principalmente por el nivel de consumo energético. Aunque la hora del día modula estos comportamientos, no es la variable determinante de la estructura latente. En cambio, el consumo (KWH) se alinea de manera directa con PC1, confirmando que la carga es el principal eje de variación para los datos.

Reducción No Lineal con UMAP



Resultados del clustering

En esta visualización se muestran las relaciones no lineales en los datos, se notan los seis grupos separados, al contrario de lo que se muestra en PCA. En este caso es evidente la separación ya que están influenciadas simultáneamente por múltiples variables. El KWHD explica los clusters principales, mientras que el resto son interacciones más leves, algunas pueden ser la distorsión armónica, corrientes, tensiones y desbalances. La hora del día las modula, pero no las determina, similar a la observación anterior.

K-MEANS CLUSTERING

Análisis Comparativo: K-Means vs. DBSCAN en Perfiles de Carga Eléctrica

Enfoque K-Means (Visión Simplificada)

Este enfoque permitió identificar dos patrones dominantes de operación en los puntos de medición, reflejando los comportamientos más frecuentes en la red durante el día y la noche. Su naturaleza particional y centrada en promedios genera una visión global, útil para estrategias operativas generales.

Perfil 1: Alta Carga Operativa (52.3%)

Horario típico: 8:00–20:00 (diurno, jornada productiva)

Consumo promedio: 21.03 ± 4.58 kWh

Calidad eléctrica: Factor de potencia 0.98, THD = 0.16

Interpretación: Periodos de plena actividad industrial o comercial. Equipos en régimen estable, baja distorsión armónica y eficiencia energética adecuada.

Estado operativo: Óptimo — balance entre consumo y calidad, sin indicios de sobrecarga o pérdidas significativas.

Perfil 2: Baja Carga / Reposo (47.7%)

Horario típico: 0:00–6:00 (nocturno)

Consumo promedio: 6.96 ± 2.00 kWh

Calidad eléctrica: Factor de potencia 0.99, THD = 0.36

Interpretación: Periodos de reposo, con cargas auxiliares y equipos en standby. El THD más elevado indica presencia de cargas no lineales (UPS, iluminación LED o variadores).

Estado operativo: Requiere atención preventiva — el bajo nivel de carga amplifica las distorsiones armónicas, lo cual puede afectar el desempeño de equipos sensibles.

Conclusión K-Means:

Permite una segmentación macro-operativa (día/noche o producción/reposo). Sin embargo, su suposición de clusters esféricos limita la detección de eventos atípicos o transitorios.

Enfoque DBSCAN (Visión Granular)

A diferencia de K-Means, DBSCAN identifica estructuras de densidad y es capaz de descubrir patrones menos frecuentes y puntos anómalos sin requerir un número fijo de clusters. Esto permitió revelar comportamientos adicionales no visibles en la agrupación tradicional.

Perfil 3: Pico Máximo (11.3%)

Momento característico: Transiciones matutinas (6:00–8:00) o vespertinas (18:00–20:00)

Consumo promedio: 35.8 ± 6.9 kWh

Calidad eléctrica: Factor de potencia 0.95, THD = 0.22

Interpretación: Corresponde a periodos de arranque o cierre de operaciones, donde múltiples equipos se energizan simultáneamente.

Riesgo: Alta demanda instantánea, posibles penalizaciones por potencia reactiva o sobrecarga térmica en transformadores.

Recomendación: Aplicar estrategias de gestión de demanda o desfase de arranque de equipos críticos.

Perfil 4: Anomalías / Eventos Irregulares (32.3%)

Descripción: Lecturas dispersas fuera del patrón habitual, etiquetadas por DBSCAN como clusters de baja densidad o ruido.

Posibles causas:

Fluctuaciones de tensión (picos o caídas momentáneas)

Lecturas defectuosas o pérdida parcial de datos

Conexión irregular de cargas no monitoreadas

Impacto: Estos eventos representan oportunidades para detección temprana de fallos o mantenimiento predictivo.

Recomendación: Crear una rutina de validación automática de mediciones y correlacionar estos puntos con registros de alarmas o eventos en campo.

Conclusión

DBSCAN:

Aporta una visión más granular y operacionalmente útil, permitiendo distinguir entre condiciones normales, picos y anomalías. Es especialmente valioso en contextos donde existen variaciones no lineales o comportamiento irregular, como en redes de distribución o plantas industriales.

INSIGHTS ACCIONABLES Y RECOMENDACIONES ESTRATÉGICAS

Desbalance de Fases

- Observación: 398 observaciones (13.8%) con desbalance >20%
- Impacto: Sobre calentamiento de neutro, pérdidas
- Recomendación: Redistribuir cargas entre fases
- Beneficio: Reducción 5-8% en pérdidas de distribución

Gestión de Demanda

- Observación: Pico de 22.4 kWh entre 11:00-14:00
- Oportunidad: Diferir cargas no críticas a valle (0:00-6:00)
- Recomendación: Implementar gestión de demanda programada
- Beneficio: Reducción de demanda máxima facturable

Investigación de Anomalías

- Observación: 931 eventos (32.3%) no clasificables
- Acción: Auditoría técnica de estos períodos
- Posibles Causas:
 - Arranques de equipos pesados
 - Transitorios eléctricos
 - Equipos defectuosos
 - Operaciones manuales no programadas
- Recomendación: Cruzar con logs operativos y mantenimiento

CONCLUSIONES Y TRABAJO FUTURO

CONCLUSIÓN

El desarrollo de este proyecto permitió cumplir de manera íntegra y rigurosa todos los objetivos planteados, avanzando desde el análisis exploratorio hasta la caracterización de perfiles operativos y la identificación de oportunidades de mejora en el comportamiento eléctrico del sistema estudiado. El proceso inició con una fase exhaustiva de limpieza y preprocesamiento, donde se consolidó un dataset robusto y enriquecido mediante la creación de nuevas variables y la detección de 389 outliers, los cuales resultaron ser elementos valiosos para el entendimiento de eventos reales.

La aplicación de técnicas de reducción dimensional, especialmente PCA y UMAP, permitió revelar la estructura subyacente de los datos. Mientras PCA explicó casi el 70% de la variabilidad con solo tres componentes, UMAP aportó una perspectiva no lineal más rica, evidenciando visualmente la presencia de 5–6 conglomerados naturales. Estas representaciones fueron fundamentales para seleccionar y aplicar los algoritmos de clustering más adecuados.

La fase de agrupamiento confirmó la existencia de patrones operativos bien definidos. K-means reveló dos perfiles principales con una clara división entre periodos de alta carga diurna y baja carga nocturna, mientras que DBSCAN ofreció una visión más granular al detectar tres clusters estructurados y, adicionalmente, un 32.3% de eventos anómalos. Este comportamiento resalta la capacidad de DBSCAN para manejar distribuciones densidad-dependientes, así como para reconocer automáticamente irregularidades del sistema. Ambas técnicas, evaluadas con métricas como Silhouette, Calinski-Harabasz y Davies-Bouldin, demostraron un desempeño adecuado, aunque DBSCAN mostró un rendimiento ligeramente superior en este contexto.

Los hallazgos derivados del análisis ofrecen una lectura profunda del funcionamiento eléctrico: la relación inversa entre consumo y distorsión armónica, la significativa presencia de anomalías, el desbalance moderado entre fases y la solidez del patrón bimodal de carga aportan información crítica para la toma de decisiones. En conjunto, estos insights generan un valor agregado tangible, proporcionando una base técnica para la gestión proactiva de energía, la priorización de intervenciones operativas y el diseño futuro de sistemas de monitoreo continuo.

Metodológicamente, la integración de reducción de dimensionalidad, clustering y feature engineering demostró ser altamente efectiva para capturar la estructura latente de los datos. Las lecciones aprendidas destacan la importancia de mantener los outliers en contextos eléctricos, el impacto positivo de las variables temporales cíclicas en la agrupación, y el valor estratégico de visualizaciones avanzadas como UMAP para la comprensión inicial del sistema.

En síntesis, el proyecto no solo cumplió con sus objetivos académicos, sino que también entregó un análisis aplicable, interpretativo y accionable, capaz de servir como punto de partida para iniciativas de optimización energética, detección automática de eventos y sistemas inteligentes de supervisión.

TRABAJO FUTURO

- Validación temporal:

- Replicar análisis con datos de múltiples meses
 - Identificar variaciones estacionales
 - Validar estabilidad de perfiles
- Análisis predictivo:
 - Desarrollar modelos de forecasting de demanda
 - Predicción de anomalías en tiempo real
 - Alertas automáticas de desviaciones
- Evaluación comparativa
 - Comparar con otros clientes industriales y del sector
 - Identificar mejores prácticas
 - Cuantificar potencial de mejora
- Implementación operacional
 - Dashboard interactivo para seguimiento continuo
 - Sistema de alertas automáticas
 - Recomendaciones dinámicas basadas en los perfiles de los cliente

REFERENCIAS BIBLIOGRÁFICAS

- Silhouette Score: Rousseeuw, P.J. (1987). Silhouettes: A graphical aid to interpretation.
- Davies-Bouldin Index: Davies, D.L., Bouldin, D.W. (1979). A cluster separation measure.
- Calinski-Harabasz Index: Caliński, T., Harabasz, J. (1974). A dendrite method for cluster analysis.